

SISTEMI INTELLIGENTI PER INTERNET

Pipeline Analitica Integrata per il Dataset Yelp

Sistemi Intelligenti & Machine Learning: dall'acquisizione dei testi al Deep Learning, una soluzione modulare

Valerio Fiorentini | Matricola 641622



Dataset Yelp

recensioni, utenti e locali

Obiettivi: Sistemi Intelligenti per Internet



Recommender Systems

Suggerire locali in modo personalizzato



Information Retrieval

Trovare e filtrare le informazioni rilevanti



Social Search

Sfruttare le interazioni sociali degli utenti



Text Processing

Estrarre significato dalle recensioni



Il caso di studio

Il dataset Yelp (oltre 5 GB di recensioni, utenti e locali) come banco di prova per le quattro aree del corso.

Architettura della soluzione



Artifact Layer su Google Drive · artefatti intermedi salvati tra una fase e l'altra



Focus

Text Acquisition, Information Retrieval e interazioni sociali.



Dashboard Streamlit

Un'unica interfaccia per esplorare tutte le fasi.

Ingestion, EDA e geospaziale



Ingestion

Filtro rapido sul settore Food/Ristorazione.




Dinamiche temporali

Picchi di affluenza individuati con matrici (venerdì e sabato sera).



Cartografia

Confronto tra reti urbane (Las Vegas ortogonale vs città europee) e mappe Folium.



Dashboard Streamlit: esplorazione geospaziale (Philadelphia)

Social Network Analysis



Opinion leader

Influencer estratti con la Degree Centrality.



Community Detection


Partizionamento di Louvain.

80%

Power-law

degli utenti scrive al massimo
5 recensioni

1. Spring Layout (Community Detection)



Spring layout: community detection

Text Mining e sentiment



Word Cloud

Positive (cortesia, cibo) vs negative (attese, servizio freddo).




Topic Modeling (LDA)

5 macro-argomenti: servizio, cibo, attese, prezzo, atmosfera.



Modelli predittivi

Logistic Regression con TF-IDF e Multinomial Naive Bayes.



Sistemi di raccomandazione ibridi

1

Content-Based (KNN)

Immune al cold-start: usa attributi (parcheggio, cucina, atmosfera), latenza minima.

2


Collaborative Filtering (SVD)

Estrae relazioni latenti.

3

Deep Learning (Keras Embeddings)

Massima accuratezza per suggerimenti super-personalizzati.



Dashboard Streamlit: motore di raccomandazione multi-paradigma

Risultati

F1 Sentiment

0.97

classificatore TF-IDF

AUC Sentiment

0.985

capacità di separare le classi

MAE


0.76

errore medio < 1 stella

RMSE

0.94

Deep Learning recommender




In parole semplici

Il modello neurale sbaglia in media di meno di 1 stella (0.76).

KNN risponde in ~55 ms, ideale per app in tempo reale; il Deep Learning impiega ~436 ms: più lento, ma più preciso.

Integrazione: Unified Yelp Analytics



Dashboard Streamlit: benchmark pipeline 01-05



Valore di business

Integrare LDA e rating per capire perché un locale perde stelle.



Trade-off

Latenza vs accuratezza: KNN ~55 ms contro Deep Learning ~436 ms.



Dashboard unica

Profilazione, sentiment, topic analysis e raccomandazione.

Conclusioni

Integrazione efficace di Social Search, Text Processing e Recommender Systems.



Accesso all'informazione

Da recensioni e interazioni a
raccomandazioni utili



Modularità

Cinque moduli indipendenti



Completezza analitica

Dall'ingestion alla BI